

Análise, Visualização e Comunicação de Dados

Laboratórios de Sistemas e Serviços

Mário Antunes

Universidade de Aveiro

2026

Dos Dados ao Conhecimento

Carregamento e Manipulação de Dados

Limpeza de Dados

Análise Exploratória de Dados (EDA)

Visualização de Dados

Comunicação e Partilha de Dados


Sumário

Dos Dados ao Conhecimento

A jornada dos dados brutos ao conhecimento acionável.

- **Dados:** Factos ou observações discretas e objetivas.
- **Informação:** Dados processados para serem úteis; responde a “Quem, Quê, Onde, Quando”.
- **Conhecimento:** Aplicação de dados e informação; responde a “Como”.
- **Sabedoria:** Compreensão avaliada; responde a “Porquê”.

A Pirâmide DIKW



- À medida que subimos na pirâmide, o **significado** e o **valor** aumentam.
- Como engenheiros, construímos sistemas que automatizam esta transformação.

A Pipeline de Ciência de Dados I

Um fluxo de trabalho padrão para tirar partido dos dados.

1. **Recolha:** Obter dados de sensores, APIs ou bases de dados.
2. **Limpeza:** Lidar com valores em falta, ruído e outliers.
3. **Exploração (EDA):** Compreender as propriedades estatísticas dos dados.
4. **Análise:** Construir modelos ou realizar consultas complexas.
5. **Visualização:** Comunicar os resultados de forma eficaz.

- **Iteração:** A pipeline não é linear; muitas vezes volta-se à limpeza após a exploração.
- **Automação:** Usar scripts (Python) e pipelines para tornar o processo repetível.
- **Qualidade:** “Lixo à entrada, lixo à saída” – a fase de limpeza é a mais crítica.

Carregamento e Manipulação de Dados

O Conceito de DataFrame I

Um DataFrame é a estrutura de dados central na ciência de dados moderna.

- **Modelo Conceptual:** Uma folha de cálculo em memória ou uma tabela SQL.
- **Eixo 0:** Linhas (Amostras/Observações).
- **Eixo 1:** Colunas (Variáveis/Características).
- **Índice:** Rótulos únicos para identificar as linhas.

O Conceito de DataFrame II

- **Homogeneidade:** Cada coluna geralmente contém um único tipo de dados (Int, Float, String).
- **Alinhamento:** Os dados são alinhados automaticamente com base em rótulos durante as operações.
- **Bibliotecas:** Usado por Pandas (Python), Polars (Python/Rust) e Spark (Big Data).

Ferramentas: Pandas vs. Polars

Característica	Pandas	Polars
Backend	Python / C	Rust
Threading	Single-threaded	Multi-threaded
Avaliação	Eager (Imediata)	Lazy (Preguiçosa)
Memória	Muitas cópias	Eficiente (Arrow)

- Use **Pandas** para conjuntos de dados pequenos e compatibilidade.
- Use **Polars** para desempenho e conjuntos de dados massivos.

Limpeza de Dados

Valores em Falta (Imputação)

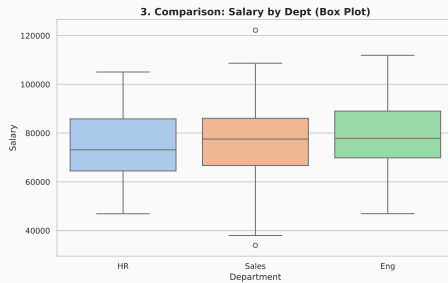
Dados do mundo real são “sujos” e muitas vezes contêm buracos (NaN, Null).

- **Drop:** Remover linhas com quaisquer valores em falta.
- **Fill (Constante):** Substituir por zero ou uma string padrão.
- **Fill (Estatístico):** Substituir pela Média, Mediana ou Moda.
- **Média:** Bom para distribuições normais.
- **Mediana:** Melhor quando existem outliers.

Deteção de Outliers com IQR

Outliers são valores extremos que podem enviesar a sua análise.

- **O Método do Box Plot:** Usa quartis para definir o intervalo “normal”.
- **IQR:** $Q3 - Q1$.
- **Limite Inferior:** $Q1 - 1.5 \times IQR$
- **Limite Superior:** $Q3 + 1.5 \times IQR$



Outliers no Box Plot

Escalonamento de Dados (Scaling)

Garantir que todas as variáveis têm um intervalo semelhante.

- **Normalização:** Escalar dados para $[0, 1]$.

■

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

- **Padronização:** Centrar os dados na Média=0 com Desvio Padrão=1.

■

$$Z = \frac{X - \mu}{\sigma}$$

Análise Exploratória de Dados (EDA)

Resumir os dados com alguns números.

- **Média / Mediana / Moda:** Tendência central.
- **Variância / Desvio Padrão:** Dispersão.
- **Quartis:** Marcadores de 25%, 50%, 75%.

Correlação (Pearson)

Medir a relação linear entre duas variáveis.

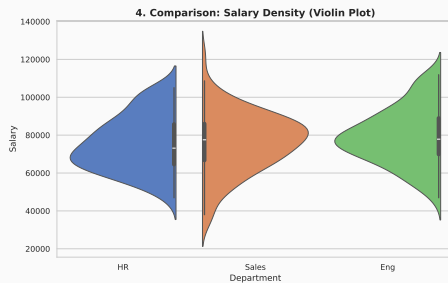
- **Intervalo:** $[-1, +1]$.
- **+1:** Relação linear positiva perfeita.
- **-1:** Relação linear negativa perfeita.
- **0:** Nenhuma relação linear.
- **Aviso:** “Correlação não implica causalidade.”

Visualização de Dados

O cérebro humano está otimizado para o reconhecimento de padrões em imagens.

- **Matplotlib:** O motor de baixo nível; controlo infinito.
- **Seaborn:** Visualização estatística de alto nível; excelentes predefinições.

- **Distribuição:** Histograma ou KDE.
- **Comparação:** Gráfico de Barras ou Box Plot.
- **Relação:** Gráfico de Dispersão ou Gráfico de Linhas.
- **Densidade:** Violin Plot (Box Plot + KDE).



Comparação de Gráficos

Exportação: Raster vs. Vetor

- **Raster (.PNG, .JPG):** Grelha de píxeis. Perde qualidade ao fazer zoom. Bom para web.
- **Vetor (.PDF, .SVG):** Caminhos matemáticos. Escalabilidade infinita. Essencial para **Artigos Acadêmicos**.

Comunicação e Partilha de Dados

Documentação e APIs são como partilhamos o conhecimento.

- **Markdown:** Para documentação técnica (READMEs).
- **LaTeX:** Para relatórios académicos formais.
- **Jupyter:** Para relatórios interativos (Notebooks).

- **Serialização:** Converter um objeto num fluxo de bytes (JSON/Protobuf).
- **Esquemas (Schemas):** Um contrato (acordo) entre produtor e consumidor.
- **Metadados:** Unidades, origem e timestamps (ISO 8601).

- **APIs REST:** O padrão para serviços web (HTTP GET/POST + JSON).
- **MQTT:** Protocolo leve para IoT (Publish/Subscribe).
- **WebSockets:** Comunicação em tempo real, full-duplex.

Sumário

- **DIKW:** Dados são a matéria-prima; Conhecimento é o objetivo.
- **Pipeline:** Limpeza e EDA são as fases mais críticas.
- **Ferramentas:** Domine Pandas/Polars para análise e Seaborn para visualização.
- **Partilha:** Use formatos padrão, esquemas e APIs para comunicar resultados.
- **Jupyter:** O laboratório para experimentação e storytelling.